

説明可能な人狼AI

なぜ、その人を疑うのか

発言には嘘がある。自分だけが知る情報もある。
判断の根拠を、他者が検討できる形で残す。

5人村 村人2・占い師1・狂人1・人狼1

先行研究と今回の問題意識

推定精度の改善だけでは、勝率改善を保証できない

2020年研究の比較	従来モデル	提案モデル
人狼推定精度	71.1%	72.3%
提案エージェント勝率	46.7%	45.3%

2024年の論理・可能世界研究を参考に、役職推定と説明を接続

出典: 早稲田ほか（2020）、Takada and Toda（2024）

役職の組合せを、世界全体で推定

24 世界

村人の自己視点

60 世界

公開情報だけの視点

入力	計算上の扱い
自己占い・確認された襲撃死	ハード制約で世界を除外
他者のCO・占い報告・投票	ソフト尤度で重みを更新

役職人数を保存する共同分布。投票は得点最大、同点は固定順。

実装で見つけた問題と設計判断

見つけた問題	採用した対策
説明の数値から私有結果が漏れる	公開履歴で分布ごと再計算
自分の宣言で確信を増幅する	自己行動を追加証拠にしない
説明の根拠を反論・検査できない	証拠ID・推論グラフ・除外再生

40 テスト

同一履歴100回の再生一致
公開説明全体の非漏洩も検査

動作例と、これから検証すること

合成局面1件の再生結果（値が小さいほど良い）

条件	Brier score	log loss	投票
ハード制約のみ	0.750	1.386	02
ソフト証拠あり	0.377	0.694	03

実戦勝率・説得効果は未検証

次は実対戦ログで尤度を検証し、推定と行動を別々に評価する